

基于多层感知机的多层介质薄膜光谱预测与辅助设计

MLP-Based Spectral Prediction and Data-Driven Design of Multilayer Dielectric Thin Films

公开版本 · 课程提交版另附身份信息

 $\lambda_{\text{target}} = 700 \text{ nm}$ $\text{seed} = 270256$ $\text{design_seed} = 270257$

摘要 / Abstract

本研究以四层介质薄膜为对象，利用传输矩阵法生成 5,000 组膜厚与 41 点反射光谱，固定划分 4,000/500/500 训练、验证和测试集。采用 4-128-128-64-41 线性输出 MLP，按验证误差选择训练检查点，测试全谱 RMSE 为 0.011375。训练样本由 500 增至 4,000 时，测试 RMSE 由 0.027351 降至 0.011375。对 10,000 组新候选进行代理筛选和 TMM 复核，有限池内 $R(700 \text{ nm})$ 最小值为 0.000204166、最大值为 0.657000。低误差预测仍可能改变候选排名，最终设计应以 TMM 为准。

关键词：光学薄膜；传输矩阵法；多层感知机；代理模型；AI for Science

Keywords: optical thin films; transfer matrix method; multilayer perceptron; surrogate model; AI for Science

1. 引言 / Introduction

多层介质薄膜利用界面反射与相干干涉调控光谱，是减反膜和高反射膜的重要基础。材料折射率、层序与膜厚共同决定反射响应，传输矩阵法（TMM）能够直接建立结构到光谱的物理映射[1,2]。传统薄膜设计可借助针式优化和遗传算法寻找目标结构[3,4]。

机器学习代理模型通过样本学习结构与光谱的非线性关系，为批量预测和候选筛选提供另一种途径[5-8]。本研究依次回答三个问题：MLP 能否准确预测 41 点反射光谱；训练样本增加后误差如何变化；代理模型能否帮助筛选 700 nm 目标膜系。研究采用统一的四层结构，并对筛选候选进行 TMM 验证。

2. 材料与方法 / Materials and Methods

2.1 光学模型与传输矩阵法 / Optical model and TMM

研究对象为正入射、无吸收且忽略色散的 Air/H/L/H/L/Glass 膜系。 $n_0=1.00$ 、 $n_H=2.30$ 、 $n_L=1.45$ 、 $n_s=1.52$ ；四层膜厚均为 40–180 nm。第 j 层相位厚度及特征矩阵为[1,2]：

$$\delta_j = 2\pi n_j d_j / \lambda$$

$$M_j = \begin{bmatrix} \cos \delta_j & i \sin \delta_j / n_j \\ i n_j \sin \delta_j & \cos \delta_j \end{bmatrix}$$

按入射侧至基底侧连乘 $M=M_1M_2M_3M_4$ ，记四个矩阵元素为 A、B、C、D，振幅反射系数及功率反射率为：

$$r = \frac{n_0 A + n_0 n_s B - C - n_s D}{n_0 A + n_0 n_s B + C + n_s D}, \quad R(\lambda) = |r|^2$$

2.2 个性化参数与固定数据集 / Parameters and fixed dataset

本研究采用 $N=56$ ，由 $\lambda_{\text{target}}=450+10 \times (N \bmod 31)$ 得到 700 nm；基准 $\text{seed}=270256$ ， $\text{design_seed}=\text{seed}+1=270257$ 。数据生成与划分使用显式设种的 $\text{np.random.default_rng}$ ；模型初始化使用 torch.manual_seed ，批次打乱使用同种子的 torch.Generator 。

以 seed 均匀独立生成 5,000 组四层膜厚，在 400–800 nm、每 10 nm 一个点的 41 点网格上计算 TMM 反射率。一次固定随机排列形成 4,000/500/500 划分。数据、光谱和划分共同保存于 `data/thinfilm_dataset.npz`，后续实验始终使用相同的验证和测试集。

2.3 MLP 与训练规模实验 / MLP and training-size experiment

MLP 为 4–128–128–64–41，隐藏层 ReLU、输出层 Linear。输入按 $(d-40)/140$ 缩放至 $[0,1]$ ；反射率保持原尺度。采用 CPU、Adam（学习率 0.001）、MSE 与批大小 128，最多 2,500 轮。验证 MSE 改善阈值 10^{-8} ，连续 100 轮未改善则早停并恢复最佳权重；选定检查点后才评估测试集。

从同一 4,000 组训练池中依次取前 500、1,000、2,000 和 4,000 组形成嵌套前缀，其他训练设置保持一致。本文报告已保存的线性输出实验；检查点、训练历史和测试指标对应同一固定划分。

2.4 代理筛选与 TMM 验证 / Surrogate screening and TMM verification

用 design_seed 生成 10,000 组新候选，按 MLP 预测 $R(700 \text{ nm})$ 分别选出最小化与最大化 Top 10，再经 TMM 重算得到各自 Top 5。额外重算同池全部 41 点光谱，比较短名单与全池排名。有限随机池极值不能代表连续膜厚空间的全局最优。




图 1. (a) 膜系结构与 TMM 数据生成；(b) 线性输出 MLP；(c) 训练规模与验证 MSE；(d) 主模型损失曲线。均来自自己发布的线性主模型材料。

Figure 1. (a) Optical stack and TMM data; (b) Linear-output MLP; (c) training size and validation MSE; (d) main-model losses. All panels use published Linear artifacts.

3. 结果 / Results

3.1 训练与测试集预测 / Training and held-out prediction

4,000 样本模型在第 1,538 轮取得最佳验证 $MSE=0.000165209$ ，训练至第 1,638 轮后停止。测试集全谱 $MSE=0.000129391$ 、 $RMSE=0.0113750$ 、 $MAE=0.00829062$ 、 $R^2=0.996053$ 。图 3a 给出固定测试集前三个样本（全局行 3758、4346、4153）的光谱对比；主谱峰及谷的位置与 TMM 结果接近。

3.2 候选池与代理排序 / Candidate pool and surrogate ranking

候选池 700 nm 预测值为 -0.0262941 至 0.6682479 ，其中 41 个 (0.41%) 越出 $[0,1]$ 。这些预测可用于代理排序，但不构成物理反射率。全池 TMM 最低值为 0.00020416604 （候选 3405），最高值为 0.65699974 （候选 2256），其预测与真实光谱见图 2a。




图 2. (a) 全候选池的 MLP-TMM 对比及全池极值光谱；(b) 两个 MLP 前 10 短名单的 TMM 复核与最优光谱。短名单排名与全池排名不同。

Figure 2. (a) Full-pool MLP-TMM comparison and extrema spectra; (b) TMM verification and best spectra of both MLP Top-10 shortlists. Shortlist and pool ranks differ.

3.3 训练数据量的影响 / Effect of training-set size

500、1,000、2,000 和 4,000 组训练的测试 RMSE 分别为 0.027351、0.019207、0.012742 和 0.011375（图 3d）。样本量从 500 增至 4,000 时误差下降约 58.41%，后期增益减小。500 和 2,000 组达到 2,500 轮上限；这说明有限预算下误差改善，但不能断言各规模均已充分收敛。




图 3. (a1–a3) 固定测试集前三个光谱; (b) 最高 RMSE 案例与绝对误差; (c) 训练与验证 MSE; (d) 数据量与测试 RMSE。案例为测试样本 313、全局行 3477。

Figure 3. (a1–a3) First three fixed-test spectra; (b) highest-RMSE case and absolute error; (c) training/validation MSE; (d) training size and test RMSE. Case: test item 313, row 3477.

3.4 代表性失败案例 / Representative failure case

固定测试集中最大全谱 RMSE 来自第 313 个样本 (test_indices[312], 全局行 3477) : RMSE=0.0295357、MAE=0.0186762。420 nm 处 TMM=0.2366349、预测=0.1465764，绝对误差 0.0900585。它是测试集高误差案例，不是设计候选；本文未设定数值失败阈值。

3.5 经 TMM 验证的短名单 / TMM-verified shortlists

表 1 按 TMM 真实反射率给出每个 MLP Top-10 短名单内的 Top 5。最小化短名单最优为候选 7207， $R(700\text{ nm})=0.001913$ ；最大化短名单最优为候选 2256， $R=0.657000$ 。全池 TMM Top 5 与 MLP Top 10 的重合数分别为 0/5 和 3/5，最大化方向重合候选为 2256、4011、7220。

表 1. 每个 MLP 前 10 短名单内经 TMM 验证的前 5 个设计。编号从 0 起，排名仅限短名单；膜厚显示至 0.1 nm。

Table 1. TMM-verified Top 5 within each MLP Top-10 shortlist. IDs are zero-based; ranks are within each shortlist. Thicknesses are rounded to 0.1 nm.

方向 Direction	排名 Rank	编号 ID	四层膜厚 Thicknesses (nm)	TMM 反射率 R(700 nm)
最小化 / Min	1	7207	(162.5, 44.8, 134.5, 57.8)	0.001913
最小化 / Min	2	2898	(161.3, 55.9, 126.9, 66.7)	0.002115
最小化 / Min	3	531	(159.4, 62.6, 128.4, 53.3)	0.002221
最小化 / Min	4	3612	(163.8, 47.1, 129.5, 105.0)	0.003081
最小化 / Min	5	5085	(164.0, 40.4, 122.2, 108.5)	0.003327
最大化 / Max	1	2256	(72.4, 129.6, 75.5, 117.7)	0.657000
最大化 / Max	2	4011	(71.5, 120.7, 81.0, 115.2)	0.656284
最大化 / Max	3	7220	(73.0, 113.8, 78.0, 138.8)	0.654467
最大化 / Max	4	39	(69.4, 133.4, 73.8, 109.5)	0.654322
最大化 / Max	5	5660	(79.6, 116.3, 73.3, 151.0)	0.654308

4. 讨论 / Discussion

Q1：在给定物理假设和固定测试集上，MLP 能够近似四层膜厚到光谱的映射，全谱 RMSE 约为 0.0114。然而平均误差无法保证每个谱谷都准确，测试高误差案例在 420 nm 处存在约 0.0901 的偏差。对局部快速变化光谱的不足是可能解释，仍需更广泛实验验证。

Q2：增加训练样本可降低本次固定划分上的预测误差，但误差下降幅度逐渐减小，且小样本实验受训练轮数上限影响。该结果支持扩大数据覆盖的价值，尚不能推广至不同材料、层数或随机划分。

Q3：MLP 可以批量产生候选排名，帮助定位需物理复核的结构。最大化短名单保留了全池最优候选，最小化短名单则遗漏全池 Top 5。即使全谱平均误差较低，近零反射率候选的排序仍可能受影响，最终膜系应依据 TMM 确认。本文没有进行相同硬件上的速度基准测试，不给出加速倍数。

4.1 研究局限 / Limitations

研究只考虑固定实数折射率、无吸收、正入射的 TMM 合成数据；不含色散、偏振、实验噪声和制造误差。仅使用一个固定数据划分和有限训练预算。候选池极值属于离散随机样本，不代表连续设计空间全局最优；线性输出的越界结果也表明需保留物理验证步骤。

5. 结论 / Conclusions

本研究完成了 TMM 数据生成、MLP 光谱预测、训练规模实验和候选设计验证。4,000 组训练的测试 RMSE 为 0.011375，较 500 组下降约 58.41%。MLP 能辅助筛选，但低反射率短名单遗漏全池 Top 5；全池 R(700 nm) 极值为 0.000204166 和 0.657000。增加样本改善本次预测表现，最终设计仍需 TMM 验证。

数据与代码可用性 / Data and Code Availability

源代码、固定 TMM 数据、线性主模型检查点、损失历史、候选光谱、设计表和论文均可在下列公开仓库获取。

Source code, fixed TMM data, the Linear checkpoint, loss histories, candidate spectra, design tables and article are available in this public repository.

<https://github.com/xiong1971511-maker/ai4s-thinfilm-project>

README 记录 700 nm、seed=270256、design_seed=270257 及全流程命令。数据位于 data/thinfilm_dataset.npz，主检查点为 models_convergence_linear/mlp_train_4000.pt；训练与设计结果在 outputs_convergence_linear/，图源在 paper/figures/，高误差案例为 paper/heldout_test_case_row_3477_spectra.csv。

The README records 700 nm, seed=270256, design_seed=270257 and reproduction commands. Data: data/thinfilm_dataset.npz; checkpoint: models_convergence_linear/mlp_train_4000.pt; results: outputs_convergence_linear/; figures: paper/figures/; held-out case: paper/heldout_test_case_row_3477_spectra.csv.

数值复核与图表重建分别运行 scripts/verify_submission.py 和 scripts/make_submission_figures.py。从零训练使用已记录设置；跨平台浮点差异可能改变优化轨迹。仓库须在本学期保持可访问。

Verify results with scripts/verify_submission.py and rebuild figures with scripts/make_submission_figures.py. From-scratch training uses the recorded settings; cross-platform floating-point differences may change optimization trajectories. Keep the repository accessible throughout the semester.

参考文献 / References

1. MacLeod, H. A. Thin-Film Optical Filters, 4th ed. Boca Raton, FL: CRC Press, 2010. doi:10.1201/9781420073034.
2. Byrnes, S. J. "Multilayer optical calculations." arXiv, arXiv:1603.02720 (2016). doi:10.48550/arXiv.1603.02720.
3. Tikhonravov, A. V., Trubetskov, M. K., & DeBell, G. W. "Application of the needle optimization technique to the design of optical coatings." Applied Optics, 35(28), 5493–5508 (1996). doi:10.1364/AO.35.005493.
4. Schubert, M. F., Mont, F. W., Chhajed, S., Poxson, D. J., Kim, J. K., & Schubert, E. F. "Design of multilayer antireflection coatings made from co-sputtered and low-refractive-index materials by genetic algorithm." Optics Express, 16(8), 5290–5298 (2008). doi:10.1364/OE.16.005290.
5. Liu, Z., Zhu, D., Raju, L., & Cai, W. "Tackling photonic inverse design with machine learning." Advanced Science, 8(5), 2002923 (2021). doi:10.1002/advs.202002923.
6. Unni, R., Yao, K., Han, X., Zhou, M., & Zheng, Y. "A mixture-density-based tandem optimization network for on-demand inverse design of thin-film high reflectors." Nanophotonics, 10(16), 4057–4065 (2021). doi:10.1515/nanoph-2021-0392.
7. Ma, T., Tobah, M., Wang, H., & Guo, L. J. "Benchmarking deep learning-based models on nanophotonic inverse design problems." Opto-Electronic Science, 1(1), 210012 (2022). doi:10.29026/oes.2022.210012.
8. Ma, T., Ma, M., & Guo, L. J. "Optical multilayer thin film structure inverse design: From optimization to deep learning." iScience, 28(4), 112222 (2025). doi:10.1016/j.isci.2025.112222.