

基于多层感知机的多层介质薄膜光谱预测与辅助设计

MLP-Based Spectral Prediction and Data-Driven Design of Multilayer Dielectric Thin Films

公开版本 · 课程提交版另附身份信息

 $\lambda_{\text{target}} = 700 \text{ nm}$ $\text{seed} = 270256$ $\text{design_seed} = 270257$

Abstract

本研究以四层介质薄膜为对象，利用传输矩阵法生成 5,000 组膜厚与 41 点反射光谱，固定划分 4,000/500/500 训练、验证和测试集。采用 4-128-128-64-41 线性输出 MLP，按验证误差选择训练检查点，测试全谱 RMSE 为 0.011375。训练样本由 500 增至 4,000 时，测试 RMSE 由 0.027351 降至 0.011375。对 10,000 组新候选进行代理筛选和 TMM 复核，有限池内 $R(700 \text{ nm})$ 最小值为 0.000204166、最大值为 0.657000。低误差预测仍可能改变候选排名，最终设计应以 TMM 为准。

Keywords: optical thin films; transfer matrix method; multilayer perceptron; surrogate model; AI for Science

1. Introduction

多层介质薄膜利用界面反射与相干干涉调控光谱，是减反膜和高反射膜的重要基础。材料折射率、层序与膜厚共同决定反射响应，传输矩阵法（TMM）能够直接建立结构到光谱的物理映射[1,2]。传统薄膜设计可借助针式优化和遗传算法寻找目标结构[3,4]。

机器学习代理模型通过样本学习结构与光谱的非线性关系，为批量预测和候选筛选提供另一种途径[5-8]。本研究依次回答三个问题：MLP 能否准确预测 41 点反射光谱；训练样本增加后误差如何变化；代理模型能否帮助筛选 700 nm 目标膜系。研究采用统一的四层结构，并对筛选候选进行 TMM 验证。

2. Materials and Methods

2.1 Optical model and transfer matrix method

研究对象为正入射、无吸收且忽略色散的 Air/H/L/H/L/Glass 膜系。 $n_0=1.00$ 、 $n_H=2.30$ 、 $n_L=1.45$ 、 $n_s=1.52$ ；四层膜厚均为 40–180 nm。第 j 层相位厚度及特征矩阵为[1,2]：

$$\delta_j = 2\pi n_j d_j / \lambda$$

$$M_j = \begin{bmatrix} \cos \delta_j & i \sin \delta_j / n_j \\ i n_j \sin \delta_j & \cos \delta_j \end{bmatrix}$$

按入射侧至基底侧连乘 $M=M_1M_2M_3M_4$ ，记四个矩阵元素为 A、B、C、D，振幅反射系数及功率反射率为：

$$r = \frac{n_0 A + n_0 n_s B - C - n_s D}{n_0 A + n_0 n_s B + C + n_s D}, \quad R(\lambda) = |r|^2$$

2.2 Personal parameters and fixed dataset

本研究采用 $N=56$ ，由 $\lambda_{\text{target}}=450+10 \times (N \bmod 31)$ 得到 700 nm；基准 $\text{seed}=270256$ ， $\text{design_seed}=\text{seed}+1=270257$ 。数据生成与划分使用显式设种的 $\text{np.random.default_rng}$ ；模型初始化使用 torch.manual_seed ，批次打乱使用同种子的 torch.Generator 。

以 seed 均匀独立生成 5,000 组四层膜厚，在 400–800 nm、每 10 nm 一个点的 41 点网格上计算 TMM 反射率。一次固定随机排列形成 4,000/500/500 划分。数据、光谱和划分共同保存于 `data/thinfilm_dataset.npz`，后续实验始终使用相同的验证和测试集。

2.3 MLP and training-size experiment

MLP 结构为 4–128–128–64–41，隐藏层使用 ReLU，输出层为 Linear。膜厚按 $(d-40)/140$ 缩放至 $[0,1]$ ，反射率保持原数值尺度。训练使用 CPU、Adam、学习率 0.001、MSE 损失和 128 批大小；最多 2,500 轮，验证 MSE 改善阈值为 10^{-8} ，连续 100 轮未改善时早停并恢复最佳权重。测试集仅在检查点选择后评估。

从同一 4,000 组训练池中依次取前 500、1,000、2,000 和 4,000 组形成嵌套前缀，其他训练设置保持一致。本文报告已保存的线性输出实验；检查点、训练历史和测试指标对应同一固定划分。

2.4 MLP-assisted screening and TMM verification

用 design_seed 生成 10,000 组新候选，按 MLP 预测的 $R(700 \text{ nm})$ 分别形成最小化和最大化 Top 10；以 TMM 重算这两个短名单，得到各自 Top 5。另对同一 10,000 组候选的全光谱进行 TMM 复核，用于评估短名单与全池排名差异。全池极值仅指有限随机池，不能推断连续膜厚空间的全局最优。




Figure 1. (a) Optical stack and TMM data generation; (b) Linear MLP architecture; (c) validation MSE versus training size; (d) main-model loss histories. All panels use the published Linear artifacts.

3. Results

3.1 Training and held-out prediction

4,000 样本模型在第 1,538 轮取得最佳验证 $MSE=0.000165209$ ，训练至第 1,638 轮后停止。测试集全谱 $MSE=0.000129391$ 、 $RMSE=0.0113750$ 、 $MAE=0.00829062$ 、 $R^2=0.996053$ 。Figure 3a 给出固定测试集前三个样本（全局行 3758、4346、4153）的光谱对比；主谱峰及谷的位置与 TMM 结果接近。

3.2 Candidate pool and surrogate ranking

候选池 700 nm 预测值为 -0.0262941 至 0.6682479 ，其中 41 个 (0.41%) 越出 $[0,1]$ 。这些预测可用于代理排序，但不构成物理反射率。全池 TMM 最低值为 0.00020416604 （候选 3405），最高值为 0.65699974 （候选 2256），其预测与真实光谱见 Figure 2a。




Figure 2. (a) Linear predictions against full-pool TMM values and spectra of the pool extrema; (b) TMM verification of each MLP Top-10 shortlist and its best verified spectrum. Shortlist ranks and full-pool ranks are distinct.

3.3 Effect of training-set size

500、1,000、2,000 和 4,000 组训练的测试 RMSE 分别为 0.027351、0.019207、0.012742 和 0.011375 (Figure 3d)。样本量从 500 增至 4,000 时误差下降约 58.41%，后期增益减小。500 和 2,000 组达到 2,500 轮上限；这说明有限预算下误差改善，但不能断言各规模均已充分收敛。




Figure 3. (a1–a3) First three fixed-test spectra; (b) highest-RMSE held-out case and its absolute error; (c) training/validation MSE; (d) test RMSE versus training size. The failure case is test item 313, global row 3477, selected by 41-point RMSE.

3.4 Representative failure case

固定测试集中最大全谱 RMSE 来自第 313 个样本 (test_indices[312], 全局行 3477) : RMSE=0.0295357、MAE=0.0186762。420 nm 处 TMM=0.2366349、预测=0.1465764, 绝对误差 0.0900585。它是测试集高误差案例, 不是设计候选; 本文未设定数值失败阈值。

3.5 TMM-verified final shortlists

Table 1 按 TMM 真实反射率给出每个 MLP Top-10 短名单内的 Top 5。最小化短名单最优为候选 7207， $R(700\text{ nm})=0.001913$ ；最大化短名单最优为候选 2256， $R=0.657000$ 。全池 TMM Top 5 与 MLP Top 10 的重合数分别为 0/5 和 3/5，最大化方向重合候选为 2256、4011、7220。

Table 1. Top five TMM-verified designs within each MLP Top-10 shortlist. IDs are zero-based candidate indices; ranks apply within the shortlist. Thicknesses are rounded to 0.1 nm for display.

Direction	Rank	ID	Four-layer thickness (nm)	TMM R(700 nm)
Minimize	1	7207	(162.5, 44.8, 134.5, 57.8)	0.001913
Minimize	2	2898	(161.3, 55.9, 126.9, 66.7)	0.002115
Minimize	3	531	(159.4, 62.6, 128.4, 53.3)	0.002221
Minimize	4	3612	(163.8, 47.1, 129.5, 105.0)	0.003081
Minimize	5	5085	(164.0, 40.4, 122.2, 108.5)	0.003327
Maximize	1	2256	(72.4, 129.6, 75.5, 117.7)	0.657000
Maximize	2	4011	(71.5, 120.7, 81.0, 115.2)	0.656284
Maximize	3	7220	(73.0, 113.8, 78.0, 138.8)	0.654467
Maximize	4	39	(69.4, 133.4, 73.8, 109.5)	0.654322
Maximize	5	5660	(79.6, 116.3, 73.3, 151.0)	0.654308

4. Discussion

Q1：在给定物理假设和固定测试集上，MLP 能够近似四层膜厚到光谱的映射，全谱 RMSE 约为 0.0114。然而平均误差无法保证每个谱谷都准确，测试高误差案例在 420 nm 处存在约 0.0901 的偏差。对局部快速变化光谱的不足是可能解释，仍需更广泛实验验证。

Q2：增加训练样本可降低本次固定划分上的预测误差，但误差下降幅度逐渐减小，且小样本实验受训练轮数上限影响。该结果支持扩大数据覆盖的价值，尚不能推广至不同材料、层数或随机划分。

Q3：MLP 可以批量产生候选排名，帮助定位需物理复核的结构。最大化短名单保留了全池最优候选，最小化短名单则遗漏全池 Top 5。即使全谱平均误差较低，近零反射率候选的排序仍可能受影响，最终膜系应依据 TMM 确认。本文没有进行相同硬件上的速度基准测试，不给出加速倍数。

4.1 Limitations

研究只考虑固定实数折射率、无吸收、正入射的 TMM 合成数据；不含色散、偏振、实验噪声和制造误差。仅使用一个固定数据划分和有限训练预算。候选池极值属于离散随机样本，不代表连续设计空间全局最优；线性输出的越界结果也表明需保留物理验证步骤。

5. Conclusions

本研究完成了 TMM 数据生成、MLP 光谱预测、训练规模实验和候选设计验证。4,000 组训练的测试 RMSE 为 0.011375，较 500 组下降约 58.41%。MLP 能辅助筛选，但低反射率短名单遗漏全池 Top 5；全池 R(700 nm) 极值为 0.000204166 和 0.657000。增加样本改善本次预测表现，最终设计仍需 TMM 验证。

Data and Code Availability

All source code, the fixed TMM dataset, published Linear checkpoint, loss histories, candidate spectra, ranked design tables and final article are available in the public repository:

<https://github.com/xiong1971511-maker/ai4s-thinfilm-project>

The README reports target=700 nm, seed=270256 and design_seed=270257, with commands for data generation, training, screening, verification and figure reproduction. The dataset is data/thinfilm_dataset.npz; the main checkpoint is models_convergence_linear/mlp_train_4000.pt. Training and design results are in outputs_convergence_linear/. Figure sources and their manifest are in paper/figures/. The held-out case is provided as paper/heldout_test_case_row_3477_spectra.csv.

Published numerical results can be verified using scripts/verify_submission.py and all three figures regenerated using scripts/make_submission_figures.py. Training from scratch uses the recorded settings; floating-point differences across operating systems and Python versions can change optimization trajectories. The repository should remain accessible throughout the semester.

References

1. MacLeod, H. A. Thin-Film Optical Filters, 4th ed. Boca Raton, FL: CRC Press, 2010. doi:10.1201/9781420073034.
2. Byrnes, S. J. "Multilayer optical calculations." arXiv, arXiv:1603.02720 (2016). doi:10.48550/arXiv.1603.02720.
3. Tikhonravov, A. V., Trubetskov, M. K., & DeBell, G. W. "Application of the needle optimization technique to the design of optical coatings." Applied Optics, 35(28), 5493–5508 (1996). doi:10.1364/AO.35.005493.
4. Schubert, M. F., Mont, F. W., Chhajed, S., Poxson, D. J., Kim, J. K., & Schubert, E. F. "Design of multilayer antireflection coatings made from co-sputtered and low-refractive-index materials by genetic algorithm." Optics Express, 16(8), 5290–5298 (2008). doi:10.1364/OE.16.005290.
5. Liu, Z., Zhu, D., Raju, L., & Cai, W. "Tackling photonic inverse design with machine learning." Advanced Science, 8(5), 2002923 (2021). doi:10.1002/advs.202002923.
6. Unni, R., Yao, K., Han, X., Zhou, M., & Zheng, Y. "A mixture-density-based tandem optimization network for on-demand inverse design of thin-film high reflectors." Nanophotonics, 10(16), 4057–4065 (2021). doi:10.1515/nanoph-2021-0392.
7. Ma, T., Tobah, M., Wang, H., & Guo, L. J. "Benchmarking deep learning-based models on nanophotonic inverse design problems." Opto-Electronic Science, 1(1), 210012 (2022). doi:10.29026/oes.2022.210012.
8. Ma, T., Ma, M., & Guo, L. J. "Optical multilayer thin film structure inverse design: From optimization to deep learning." iScience, 28(4), 112222 (2025). doi:10.1016/j.isci.2025.112222.